Este é o **Manual de Bolso do Nex Chat**, um guia rápido para instalação, operação e manutenção do seu sistema de IA 100% local.

🚀 Início Rápido (Quick Start)

Via Docker (Recomendado)
Para quem busca praticidade e isolamento:
1. `git clone https://github.com/seu-user/nex-chat.git`
2. `cd nex-chat`
3. `docker-compose up -d`
4. Acesse: **http://localhost:8000**

Via Instalação Nativa
Para maior controle sobre o ambiente:
1. **Instale o Ollama**: `curl -fsSL https://ollama.com/install.sh | sh`
2. **Baixe o Modelo**: `ollama pull gemma2:2b`
3. **Dependências**: `pip install -r requirements.txt`
4. **Executar**: `python -m src.main`

🧠 Entendendo a Memória
O Nex Chat utiliza um sistema dual de memória para conversas naturais:

* **Curto Prazo:** Mantém o contexto imediato da conversa via sistema FIFO (limite configurável).
* **Longo Prazo:** Utiliza embeddings e busca semântica para persistência de dados em JSON.

🛠️ Comandos e API
Principais endpoints para interação e automação:

Ação	Método	Endpoint
Chat Normal	`POST`	`/api/chat`
Chat Streaming	`POST`	`/api/chat/stream`
Real-time (WS)	`WS`	`/ws/chat`
Estatísticas	`GET`	`/api/stats`
Limpar Cache	`POST`	`/api/clear-cache`

📋 Requisitos de Hardware
O desempenho varia conforme o modelo escolhido e seu hardware:

* **Gemma 2 2B (Padrão):** Requer 4GB RAM.
* **Llama 3.2 1B:** Requer 2GB RAM (Ideal para máquinas modestas).
* **Phi-3 Mini:** Requer 6GB RAM.

> **Dica de Performance:** Em uma CPU de 8 cores com 16GB de RAM, o tempo de resposta médio é de 1 a 2 segundos.

🔧 Resolução de Problemas (Troubleshooting)

* **Ollama não conecta:** Execute `ollama serve` ou reinicie o container com `docker-compose restart ollama`.
* **Porta 8000 ocupada:** Inicie com uma nova porta: `PORT=8001 python -m src.main`.
* **Modelo não encontrado:** Utilize o script automático `./scripts/download_model.sh`.
* **Lentidão excessiva:** Verifique se o cache está muito cheio e limpe-o via endpoint `/api/clear-cache`.

📂 Estrutura de Arquivos Importante
* `src/core/`: Onde reside a lógica de memória e gestão de LLMs.
* `scripts/`: Ferramentas de validação e instalação.
* `docs/`: Guias detalhados de usuário e desenvolvedor.