📖 MANUAL DO USUÁRIO - SISTEMA NEX CHAT

Assistente de IA Local com Memória Persistente

📌 ÍNDICE

1. Visão Geral do Sistema
2. Instalação e Configuração
3. Interface Web - Guia de Uso
4. API - Para Usuários Avançados
5. Sistema de Memória - Como Funciona
6. Comandos Rápidos
7. Solução de Problemas
8. Dicas e Melhores Práticas
9. Glossário

📌 VISÃO GERAL

O que é o Nex Chat?

É um assistente de IA que roda **100% no seu computador** (sem internet para funcionar após instalado) e que **lembra de conversas anteriores** - mesmo dias depois!

Diferenciais

Característica	O que significa
Privacidade total	Seus dados nunca saem do seu computador
Memória de longo prazo	Lembra de você e das conversas
Grátis	Sem custos de API
Offline	Funciona sem internet

O que você pode fazer

- ✅ Fazer perguntas e obter respostas
- ✅ Ensinar coisas novas para o assistente (ele lembra)
- ✅ Ter conversas com contexto (ele lembra o que foi dito antes)

- ✅ Usar via navegador ou via programação (API)

📌 INSTALAÇÃO E CONFIGURAÇÃO

Requisitos Mínimos

Componente	Mínimo	Recomendado
Processador	4 núcleos	8 núcleos
RAM	4GB	8GB
Armazenamento	5GB livres	10GB livres
GPU	Não obrigatória	NVIDIA (qualquer)

Opção 1: Docker (Recomendado para iniciantes)

```
# 1. Clone o repositório
git clone https://github.com/seu-user/nex-chat.git
cd nex-chat

# 2. Inicie com Docker Compose
docker-compose up -d

# 3. Acesse no navegador
http://localhost:8000
```

Opção 2: Instalação Local (Windows)

```
# 1. Instale o Python 3.10+
# Baixe em: https://python.org

# 2. Abra o Prompt de Comando como Administrador

# 3. Clone o projeto
git clone https://github.com/seu-user/nex-chat.git
cd nex-chat

# 4. Crie ambiente virtual
python -m venv venv
venv\Scripts\activate

# 5. Instale dependências
pip install -r requirements.txt

# 6. Execute
python -m src.main

# 7. Acesse
http://localhost:8000
```

Opção 3: Script Automático (Windows)

```
# Execute como Administrador
scripts\validate_system.bat

# O script vai:
# - Verificar se Python está instalado
# - Instalar dependências
# - Iniciar o sistema
```

Verificando se instalou corretamente

Abra o navegador e acesse `http://localhost:8000/health`

Resposta esperada:

```
{
  "status": "healthy",
  "model": "deepseek-ai/DeepSeek-R1-Distill-Qwen-1.5B",
  "device": "cpu",
  "memory_count": 0
}
```

📌 INTERFACE WEB - GUIA DE USO

Acessando a Interface

1. Abra seu navegador (Chrome, Edge, Firefox)
2. Digite: `http://localhost:8000`
3. A interface aparecerá

Layout da Tela

```
+-------------------------------------------------+
|  NEX CHAT - IA Local                  [🌙]     |
+-------------------------------------------------+
|                                                 |
|   Bem-vindo! Como posso ajudar?                |
|                                                 |
|   [Mensagens do chat aparecem aqui]            |
|                                                 |
|                                                 |
+-------------------------------------------------+
|  [Digite sua mensagem...]             [Enviar] |
+-------------------------------------------------+
|  💡 Pressione Enter para enviar                |
+-------------------------------------------------+
```

Como conversar

1. **Digite sua pergunta** no campo de texto
2. Pressione `Enter` ou clique em `Enviar`

3. Aguarde a resposta (pode levar alguns segundos)
4. Continue a conversa - ele lembra do contexto!

Exemplos de uso

O que digitar	O que acontece
"Qual é a capital do Brasil?"	Resposta direta
"Me explique o que é machine learning"	Explicação detalhada
"Lembre-se que eu gosto de respostas curtas"	Ele salva essa preferência
"Como estava nossa conversa anterior?"	Recupera memórias

Temas (Dark/Light Mode)

- Clique no ícone 🌙 ou ☀ no canto superior direito
- Alterna entre modo escuro e claro

📌 API - PARA USUÁRIOS AVANÇADOS

Endpoints Disponíveis

Método	Endpoint	Descrição
POST	`/ask`	Envia pergunta, recebe resposta
POST	`/ask/stream`	Envia pergunta, resposta em tempo real
POST	`/remember`	Salva memória explicitamente
GET	`/memories`	Lista memórias salvas
DELETE	`/memories/{id}`	Deleta uma memória
GET	`/health`	Verifica status do sistema

Exemplo 1: Pergunta Simples

Requisição:

```
curl -X POST http://localhost:8000/ask \
  -H "Content-Type: application/json" \
  -d '{"text": "Qual é a capital do Brasil?"}'
```

Resposta:

```
{
  "response": "A capital do Brasil é Brasília.",
  "context_used": 0
}
```

Exemplo 2: Pergunta com Streaming (resposta em tempo real)

Requisição:

```
curl -X POST http://localhost:8000/ask \
  -H "Content-Type: application/json" \
  -d '{"text": "Explique o que é IA", "stream": true}'
```

Resposta: (vem em pedaços, como se a IA estivesse digitando)

```
IA significa Inteligência Artificial. É um campo da computação...
```

Exemplo 3: Salvar Memória Explicitamente

Requisição:

```
curl -X POST http://localhost:8000/remember \
  -H "Content-Type: application/json" \
  -d '{"text": "O usuário prefere respostas curtas e diretas", "importance": 1.5}'
```

Resposta:

```
{
  "status": "saved",
  "id": 42,
  "text": "O usuário prefere respostas curtas e diretas"
}
```

Exemplo 4: Listar Memórias

Requisição:

```
curl http://localhost:8000/memories?limit=10
```

Resposta:

```
{
  "memories": [
    {"id": 42, "text": "O usuário prefere respostas curtas", "importancia": 1.5},
    {"id": 43, "text": "Conversamos sobre Python ontem", "importancia": 0.8}
  ]
}
```

Parâmetros do Endpoint `/ask`

Parâmetro	Tipo	Padrão	Descrição
`text`	string	obrigatório	Sua pergunta
`max_tokens`	int	256	Tamanho máximo da resposta
`temperature`	float	0.7	Criatividade (0=exato, 1=criativo)
`stream`	bool	false	Resposta em tempo real
`use_memory`	bool	true	Usar memórias salvas

📌 SISTEMA DE MEMÓRIA - COMO FUNCIONA

Tipos de Memória

Tipo	O que guarda	Quanto tempo
Curto prazo	Contexto da conversa atual	Enquanto você conversar
Longo prazo	Fatos importantes que você ensinou	Indefinidamente

Como a memória funciona na prática

Exemplo 1: Contexto da conversa

```
Você: "Meu nome é João"
IA: "Prazer em conhecê-lo, João!"

Você: "Qual é o meu nome?"
IA: "Seu nome é João"  ← Lembrou do que foi dito antes
```

Exemplo 2: Memória de longo prazo

```
Você: "Lembre-se que eu trabalho com marketing digital"
IA: "Entendi! Vou lembrar que você trabalha com marketing."

[No dia seguinte]

Você: "O que eu faço?"
IA: "Você trabalha com marketing digital."  ← Lembrou dias depois!
```

Como ensinar coisas novas

Forma	Exemplo	Como funciona
Direta	"Lembre-se que X"	Salva imediatamente
Conversa	Falar sobre um assunto	IA aprende com o contexto
API	POST /remember	Salva explicitamente

Gerenciando memórias

Ver memórias salvas:

```
GET /memories
```

Deletar memória específica:

```
DELETE /memories/42
```

Limpar memórias antigas: O sistema faz isso automaticamente quando atinge 500 memórias

---

📌 COMANDOS RÁPIDOS

Docker

```
# Iniciar
docker-compose up -d

# Parar
docker-compose down

# Ver logs
docker-compose logs -f

# Reiniciar
docker-compose restart

# Ver status
docker-compose ps
```

Instalação Local

```
# Ativar ambiente virtual (Windows)
venv\Scripts\activate

# Ativar ambiente virtual (Linux/Mac)
source venv/bin/activate

# Executar
python -m src.main

# Executar com porta diferente
PORT=8001 python -m src.main
```

Testes

```
# Teste de saúde
curl http://localhost:8000/health

# Teste rápido
curl -X POST http://localhost:8000/ask \
  -H "Content-Type: application/json" \
  -d '{"text": "Oi, tudo bem?"}'
```

📌 SOLUÇÃO DE PROBLEMAS

Problema 1: "Não consigo acessar http://localhost:8000"

Possíveis causas:

- Sistema não iniciou
- Porta ocupada

Soluções:

```
# Verifique se o container está rodando (Docker)
docker ps

# Se não estiver, inicie
docker-compose up -d

# Ou inicie manualmente (local)
python -m src.main

# Verifique se a porta está ocupada
netstat -ano | findstr 8000

# Se estiver, mate o processo ou use outra porta
PORT=8001 python -m src.main
```

Problema 2: "Respostas muito lentas"

Causa: Modelo muito grande para seu hardware

Soluções:

1. Use modelo menor (gemma2:2b em vez de DeepSeek)
2. Reduza `max_tokens` para 128
3. Feche outros programas pesados

Problema 3: "Sem memória (Out of Memory)"

Causa: Muitas memórias salvas

Soluções:

```
# Limpar memórias antigas
curl -X DELETE http://localhost:8000/memories

# Ou no código, reduza max_memories para 200
```

Problema 4: "Erro de conexão com Ollama"

Solução:

```
# Verifique se Ollama está rodando
ollama serve

# Baixe o modelo
ollama pull gemma2:2b

# Ou mude para outro backend no config
```

Problema 5: "Modelo não baixou"

Solução manual:

```
# Baixar o modelo diretamente
ollama pull deepseek-ai/DeepSeek-R1-Distill-Qwen-1.5B
```

```
# Ou use um modelo menor
ollama pull gemma2:2b
```

📌 DICAS E MELHORES PRÁTICAS

Para respostas mais rápidas

Ação	Ganho de velocidade
Use `max_tokens=128`	50% mais rápido
Desative `use_memory`	30% mais rápido
Use modelo menor (gemma2:2b)	40% mais rápido

Para respostas mais precisas

Ação	Efeito
`temperature=0.3`	Mais factual, menos criativo
Aumente `max_tokens`	Respostas mais completas
Ensine contexto antes	Melhor compreensão

Para economia de recursos

```
# No arquivo de configuração
max_memories = 200          # Menos memórias (padrão 500)
max_tokens = 128            # Respostas mais curtas
OMP_NUM_THREADS = 1         # Menos CPU
```

Exemplos de uso produtivo

Caso de uso	Como usar
Estudos	Peça explicações, ele lembra do que já estudou
Anotações	"Lembre-se que..." - cria base de conhecimento
Brainstorm	Converse sobre ideias, ele desenvolve
Revisão	"O que discutimos sobre X?" - revisa conversas

📌 GLOSSÁRIO

Termo	Significado
API	Interface para programas se comunicarem
Embedding	Representação numérica do texto (vetor)

FAISS	Biblioteca do Facebook para busca por similaridade
GPU	Placa de vídeo, acelera processamento
IA	Inteligência Artificial
LLM	Modelo de linguagem (o "cérebro" da IA)
Memória persistente	Dados guardados no disco (não somem ao desligar)
Ollama	Software para rodar LLMs localmente
RAG	Busca em base de conhecimento para melhorar respostas
Streaming	Resposta em tempo real, como se estivesse digitando
Token	"Palavra" ou parte de palavra que a IA processa

✅ CHECKLIST - PRIMEIRO USO

- [ ] Instalei o Docker OU configurei Python localmente
- [ ] Executei `docker-compose up -d` OU `python -m src.main`
- [ ] Acessei `http://localhost:8000` no navegador
- [ ] Testei com "Qual é a capital do Brasil?"
- [ ] Testei "Lembre-se que meu nome é X"
- [ ] Testei "Qual é o meu nome?" (deve lembrar)
- [ ] Configurei tema escuro/claro (opcional)

🆘 ONDE PEDIR AJUDA

- **Erros de instalação:** Execute `scripts/validate_system.bat`
- **Problemas de memória:** Reduza `max_memories` no código
- **Dúvidas técnicas:** Consulte `docs/DEVELOPER_GUIDE.md`
- **Documentação completa:** `docs/USER_GUIDE.md`

📝 NOTAS FINAIS

Sistema 100% LOCAL - Seus dados nunca saem do seu computador

Grátis para sempre - Sem custos de API

Privacidade garantida - Ninguém vê suas conversas

Versão do Manual: 1.0
Sistema: Nex Chat
Status: PRODUCTION READY ✅

Quer que eu adicione alguma seção específica ou gere uma versão em PDF? 📄